Esercizi svolti — Statistica

Indrjo Dedej

Ultimo aggiornamento: 13 novembre 2024.

Sommario

Queste sono alcuni esercizi svolti. Possono essere problemi presenti negli esami scritti passati oppure esercitazioni.

Indice

1 Statistica Descrittiva 1
2 Statistica Inferenziale 2

1 Statistica Descrittiva

Esercizio (Problema 1, scritto del 12/02/2024)**.** Un'indagine ISTAT su $n = 100$ famiglie analizza la relazione tra il carattere X relativo alla numerosità del nucleo familiare e il carattere Y realtivo al numero di locali della rispettiva abitazione. L'indagine produce la seguente tabella

	$X = 1$	$X = 2$	$X = 3$
$Y = 2$	20	10	7
$Y = 3$	9	13	13
$Y = 4$	2	5	21

Si affrontino i seguenti quesiti.

1. Calcolare la media aritmetica (pesata) e la mediana del carattere Y.
2. Valutare la variabilità di Y tramite l'uso delle differenza media semplice (di ordine $p = 1$).
3. Valutare la concentrazione del carattere Y rispetto alla distribuzione uniforme, esplicitando il grafico della curva di Lorentz-Gini e calcolando un opportuno indice di concentrazione.
4. Calcolare la tabella relativa alla distribuzione di probabilità congiunta corrispondente alla situazione (ideale) di indipendenza dei due caratteri.
5. Scegliere un indice di connessione tra X e Y e calcolarlo numericamente coi dati forniti.
6. Calcolare la tabella corrispondente alla distribuzione di probabilità congiunta corrispondente alla situazione (ideale) di massima concordanza tra i due caratteri.
7. Scegliere un indice di concordanza tra X e Y e calcolarlo numericamente coi dati forniti.

Soluzione. 1. Cerchiamo di interpretare la tabella in termini più astratti. Abbiamo uno spazio campionario che è la popolazione sotto indagine e che chiamiamo Ω. Questo insieme è munito della sigma-algebra 2^Ω e della misura del conteggio $\mu : 2^\Omega \to [0, +\infty]$ che manda ogni singoletto $\{\omega\}$ in 1. Poi, $X, Y : \Omega \to \mathbb{R}$ sono due variabili aleatori che prendono solo un insieme finito di valori, $\{1, 2, 3\}$ e $\{2, 3, 4\}$ rispettivamente. In ogni cella della tabella stanno scritti semplicemente i valori

$$\mu[X = i, Y = j].$$

Possiamo normalizzare tutto, poiché μ è finita, e considerare la misura di probabilità $\mathbb{P} : 2^\Omega \to [0, 1]$ che manda ogni singoletto $\{\omega\}$ in $\frac{1}{n}$. La misura indotta

$$\pi_Y : \mathbb{B}R \to [0, 1], \ \pi_Y(E) := \mathbb{P}[Y \in E].$$

rappresenta quindi la distribuzione della variabile aleatoria $Y : \Omega \to \mathbb{R}$. Possiamo quindi scrivere la funzione di ripartizione

$$F_Y(t) = \mathbb{P}[Y \leq t] = \frac{37}{100}\mathbb{1}_{[2,+\infty)}(t) + \frac{35}{100}\mathbb{1}_{[3,+\infty)}(t) + \frac{28}{100}\mathbb{1}_{[4,+\infty)}(t).$$

Ecco la media aritmetica del carattere Y è quindi

$$\overline{Y} := \int_{\mathbb{R}} t \mathrm{d}F(t) = \frac{37}{100} \cdot 2 + \frac{35}{100} \cdot 3 + \frac{28}{100} \cdot 7 = 2.91$$

Calcoliamo anche la mediana del carattere Y. Abbiamo già calcolato la funzione di ripartizione, non rimane che calcolare anche la sua "inversa"

$$F_Y^{-1}(s) = \inf\{t \in \mathbb{R} \mid F(t) \geq s\}.$$

La mediana è semplicemente

$$F_Y^{-1}\left(\frac{1}{2}\right) = 3.$$

2. Richiamiamo questo indice

$$\frac{1}{\binom{n}{2}} \sum_{1 \leq i < j \leq n} |Y(\omega_i) - Y(\omega_j)|$$

dove $\Omega = \{\omega_i \mid i = 1, \dots, 100\}$. La differenza $|2 - 3| = 1$ occorre $37 \cdot 35$, la differenza $|2 - 4| = 2$ occorre $37 \cdot 28$, la differenza $|3 - 4| = 1$ occorre $35 \cdot 28$ volte. Quindi ecco eseguito il conto sopra

$$\frac{2}{100 \cdot 99}(1 \cdot 37 \cdot 35 + 2 \cdot 37 \cdot 28 + 1 \cdot 35 \cdot 28) \approx 0.88.$$

3. ...

□

2 Statistica Inferenziale

Esercizio (Problema 3, scritto del 12/02/2024)**.** Si consideri il modello statistico a n prove indipendenti avente modello base $\mathbb{X}_0 := \mathbb{R}_{>0}$, $\mathcal{X}_0 := \mathcal{B}\mathbb{R}_{>0}$, $\Theta := \mathbb{R}_{>0}$

con funzione di verosomiglianza

$$L_0 : \Theta \times \mathbb{X}_0 \to [0, +\infty]$$
$$L_0(\theta, x) := \frac{3\theta^3}{x^4} \mathbb{1}_{[\theta,+\infty)}(x)$$

dominato dalla misura unidimensionale di Lebesgue $\lambda : \mathcal{X}_0 \to [0, +\infty]$. Quindi il modello statistico base ha misure di probabilità

$$\pi_\theta^{(0)} : \mathcal{X}_0 \to [0, 1]$$
$$\pi_\theta^{(0)}(E) := \int_E L_0(\theta, \cdot) \mathrm{d}\lambda.$$

1. Determinare il modello statistico a n prove indipendenti

$$\mathbb{X}_n := \mathbb{X}_0^n, \ \mathcal{X}_n := \mathcal{X}_0^n, \ \Theta, \ \pi_\theta^{(n)} := \underbrace{\pi_\theta^{(0)} \otimes \cdots \otimes \pi_\theta^{(0)}}_{n \text{ volte}}.$$

   e scriverne la funzione di verosomiglianza $L_n : \Theta \times \mathbb{X}_n \to [\theta, +\infty]$.
2. Scrivere lo stimatore di massima verosomiglianza $\widehat{\theta}_n : \mathbb{X}_n \to \Theta$ e calcolarne la sua legge.
3. Dimostrare che $\widehat{\theta}_n$ è uno stimatore distorto ma asintoticamente non distorto. Poi calcolare uno stimatore $\widetilde{\theta}_n : \mathbb{X}_n \to \Theta$ non distorto e proporzionale a $\widehat{\theta}_n$.
4. Dimostrare, usando i teoremi visti a lezione, che $\widetilde{\theta}_n$ è fortemente consistente.
5. Fissato $n \in \mathbb{N}$ e $\alpha \in [0, 1]$, calcolare un intervallo di confidenza $C_{n,\alpha}(x_1, \dots, x_n)$ per il parametro θ di livello $1 - \alpha$.

Soluzione. 1. La funzione di verosomiglianza si scrive subito

$$L_n(\theta; x_1, \dots, x_n) = \theta^{3n} \prod_{i=1}^n \frac{\mathbb{1}_{[\theta,+\infty)}(x_i)}{x_i^4} =$$
$$= \frac{\theta^{3n}}{\left(\prod_{i=1}^n x_i\right)^4} \mathbb{1}_{[\theta,+\infty)}(\min(x_1, \dots, x_n)).$$

2. Fissato $(x_1, \dots, x_n) \in \mathbb{X}_n$, studiamo la funzione $L_n(_; x_1, \dots, x_n) : \Theta \to [0, +\infty]$. Purtroppo qui non possiamo cercare un $\widehat{\theta} \in \Theta$ che realizza $\sup_{\theta \in \Theta} L(\theta; x_1, \dots, x_n)$ derivando perché la funzione non è derivabile. Infatti:

$$L_n(\theta; x_1, \dots, x_n) = \begin{cases} \frac{\theta^{3n}}{(\prod_{i=1}^n x_i)^4} & \text{se } \theta \le \min(x_1, \dots, x_n) \\ 0 & \text{se } \theta > \min(x_1, \dots, x_n) \end{cases}$$

   Stando così le cose, si vede subito che $L(_; x_1, \dots, x_n)$ raggiunge il valore massimo per $\theta = \min(x_1, \dots, x_n)$. Quindi lo stimatore di massima veorosomiglianza è

$$\widehat{\theta} : \mathbb{X}_n \to \Theta, \ \theta(x_1, \dots, x_n) := \min(x_1, \dots, x_n).$$

   Cerchiamo la sua legge ora, e per fare ciò ci serve un po' di contesto. Siano $(\Omega, \mathcal{A}, \mathbb{P}_\theta)$ spazi di probabilità per $\theta \in \Theta$ e $X := (X_1, \dots, X_n) : \Omega \to \mathbb{X}_n$ è una variabile aleatoria tale che

$$\pi_\theta^{(n)}(E) = \mathbb{P}_\theta[X \in E] \text{ per ogni } E \in \mathcal{X}, \theta \in \Theta$$

e in cui $X_1, \dots, X_n : \Omega \to \mathbb{X}$ sono variabili aleatorie IID con densità $L_0(\theta, _) : \mathbb{X}_0 \to [0, +\infty]$. Noi cercheremo la legge per la variabile aleatoria

$$\widehat{\theta}_n(X_1, \dots, X_n) : \Omega \to \Theta.$$

Con legge intendiamo la densità oppure equivalentemente una funzione di ripartizione. Scegliamo di scrivere la funzione di ripartizione:

$$F_\theta(t) = \mathbb{P}_\theta\left[\widehat{\theta}(X_1, \dots, X_n) \le t\right] = 1 - (1 - F_{X_i,\theta}(t))^n$$

dove $F_{X_i,\theta}$ è la funzione di ripartizione di una qualsiasi delle X_i.[1] Ricordando la relazione che c'è tra funzione di ripartizione e densità di una stessa variabile aleatoria

$$F_{X_i,\theta}(t) = \int_{-\infty}^{t} L_0(\theta, x)\mathrm{d}x = \begin{cases} 0 & \text{se } t < \theta \\ 1 - \frac{\theta^3}{t^3} & \text{se } t \ge \theta \end{cases}$$

Possiamo concludere questo punto allora

$$F_\theta(t) = \begin{cases} 0 & \text{se } t < \theta \\ 1 - \frac{\theta^{3n}}{t^{3n}} & \text{se } t \ge \theta \end{cases} = \left(1 - \frac{\theta^{3n}}{t^{3n}}\right) \mathbb{1}_{[\theta, +\infty)}(t).$$

3. Per verificare se è distorto e se è asintoticamente distorto dobbiamo in ogni caso calcolare il valore attesto $\mathbb{E}_\theta\left[\widehat{\theta}_n(X_1, \dots, X_n)\right]$. Nel punto precedente abbiamo fatto dei conti che possiamo sfruttare. Infatti, la $\widehat{\theta}_n(X_1, \dots, X_n)$ ha densità $f_\theta = F'_\theta$, ed ecco allora il calcolo del valore atteso

$$\mathbb{E}_\theta\left[\widehat{\theta}_n(X_1, \dots, X_n)\right] = \int_{\mathbb{R}} t F'_\theta(t)\mathrm{d}t = \int_{\theta}^{+\infty} t\left(\frac{3n\theta^{3n}}{t^{3n+1}}\right)\mathrm{d}t = \frac{3n}{3n-1}\theta.$$

Qui di vede subito che non è corretto, ma lo è asintoticamente. Per avere uno stimatore corretto a partire da $\widehat{\theta}_n$ basta considerare

$$\widetilde{\theta}_n := \frac{3n-1}{3n}\widehat{\theta}_n.$$

4. Abbiamo visto nel punto precedente che $\widetilde{\theta}_n$ è corretto e quindi lo è pure asintoticamente. Se riusciamo a dimostrare che è anche

$$\sum_{n=1}^{+\infty} \mathrm{Var}_\theta\left[\widetilde{\theta}_n(X_1, \dots, X_n)\right] < +\infty.$$

allora abbiamo finito. Dobbiamo calcolare delle varianze, una per ogni $n \in \mathbb{N}$.

$$\begin{aligned} \mathrm{Var}_\theta\left[\widetilde{\theta}_n(X_1, \dots, X_n)\right] &= \mathbb{E}_\theta\left[\widetilde{\theta}_n(X_1, \dots, X_n)^2\right] - \theta^2 = \\ &= \left(\frac{3n-1}{3n}\right)^2 \mathbb{E}_\theta\left[\widehat{\theta}_n(X_1, \dots, X_n)^2\right] - \theta^2. \end{aligned}$$

Possiamo calcolare la media dell'ultimo membro visto che sopra abbiamo calcolato la funzione di ripartizione di $\widehat{\theta}_n(X_1, \dots, X_n)$:

$$\mathbb{E}_\theta\left[\widehat{\theta}_n(X_1, \dots, X_n)^2\right] = \int_{\mathbb{R}} t^2 F'_\theta(t)\mathrm{d}t = \int_{\theta}^{+\infty} t^2\left(\frac{3n\theta^{3n}}{t^{3n+1}}\right)\mathrm{d}t = \frac{3n}{3n-2}\theta^2.$$

Mettendo tutto insieme le varianze sono

$$\mathrm{Var}_\theta\left[\widetilde{\theta}_n(X_1, \dots, X_n)\right] = \frac{(3n-1)^2}{3n(3n-2)}\theta^2 - \theta^2 = \frac{1}{3n(3n-2)}\theta^2.$$

In conclusione la sommatoria delle varianze si comporta come la serie $\sum_{n=1} \frac{1}{9n^2}$, cioè converge.

1 Scrivere di questa cosa da qualche parte...

5. Essendo $\widetilde{\theta}_n$ uno stimatore corretto, allora un intervallo di confidenza di livello $1-\alpha$, per $\alpha \in [0,1]$, è dato da

$$C_{n,\alpha}(x_1,\dots,x_n) := \left\{ \theta \in \Theta \,\middle|\, \left|\widetilde{\theta}_n(x_1,\dots,x_n) - \theta\right| \le \sqrt{\frac{\mathrm{Var}_\theta\left[\widetilde{\theta}_n(X_1,\dots,X_n)\right]}{\alpha}} \right\}.$$

Conosciamo già la varianza e quindi

$$\gamma_{n,\alpha} := \sqrt{\frac{\mathrm{Var}_\theta\left[\widetilde{\theta}_n(X_1,\dots,X_n)\right]}{\alpha}} = \frac{1}{\sqrt{3n(3n-2)\alpha}}\theta.$$

Rimane soltanto da risolvere una disequazione

$$\left|\theta - \widetilde{\theta}_n\right| \le \gamma_{n,\alpha}\theta \iff (1-\gamma_{n,\alpha})\,\theta^2 - 2\widetilde{\theta}_n\theta + \widetilde{\theta}_n^2 \le 0$$

Se $|\gamma_{n,\alpha}| < 1$, allora

$$\frac{\widetilde{\theta}_n - \gamma_{n,\alpha}}{1-\gamma_{n,\alpha}^2} \le \theta \le \frac{\widetilde{\theta}_n + \gamma_{n,\alpha}}{1-\gamma_{n,\alpha}^2}.$$

mentre se $|\gamma_{n,\alpha}| > 1$, allora

$$\theta \le \frac{\widetilde{\theta}_n - \gamma_{n,\alpha}}{1-\gamma_{n,\alpha}^2} \text{ oppure } \theta \ge \frac{\widetilde{\theta}_n + \gamma_{n,\alpha}}{1-\gamma_{n,\alpha}^2}.$$

In ogni caso, comunque fissato $\alpha \in [0,1]$, si ha che gli intervalli di confidenza sono

$$C_{n,\alpha}(x_1,\dots,x_n) = \left[\frac{\widetilde{\theta}_n - \gamma_{n,\alpha}}{1-\gamma_{n,\alpha}^2}, \frac{\widetilde{\theta}_n + \gamma_{n,\alpha}}{1-\gamma_{n,\alpha}^2}\right]$$

definitivamente per $n \to +\infty$, cioè da un certo n in poi le regioni di confidenza sono questi intervalli.

□

Esercizio (Problema 3, 12/09/2024)**.** Si consideri il modello a n prove ripetute avente modello di base $\mathbb{X}_0 := \mathbb{R}_+$, $\mathcal{X}_0 := \mathcal{B}\mathbb{R}_+$, $\Theta := \mathbb{R}_+$ e

$$\frac{\mathrm{d}\pi_\theta^{(0)}}{\mathrm{d}\lambda_0}(x) = \frac{3\theta^3}{(\theta+x)^4}$$

dove λ_0 è la misura unidimensionale di Lebesgue ristretta a $\mathbb{R}_+$.

1. Dimostrare che
$$S_n(x_1,\dots,x_n) = \frac{2}{n}\sum_{j=1}^n x_j$$
è uno stimatore corretto di θ.
2. Dopo aver calcolato $\mathrm{Var}_\theta\left[S_n\left(X_1,\dots,X_n\right)\right]$, dimostrare (usando i teoremi visti in classe) che S_n è debolmente consistente.
3. Discutere se vale la disuguaglianza
$$\mathrm{Var}_\theta\left[S_n\left(X_1,\dots,X_n\right)\right] > \frac{1}{nI_0(\theta)}$$
dove I_0 è l'*informazione di Fisher* del modello di base.

4. Verificare (usando i teoremi di probabilità) che per ogni $\theta \in \Theta$

$$\sqrt{n}\left(S_n\left(X_1, \dots, X_n\right) - \theta\right) \to N(0, F(\theta)) \text{ in distribuzione}$$

rispetto alla probabilità $\mathbb{P}_\theta$, dove $F : \Theta \to \mathbb{R}$ è una opportuna funzione continua.

Soluzione. 1. Come al solito, dobbiamo calcolare

$$\mathbb{E}_\theta\left[S_n\left(X_1, \dots, X_n\right)\right]$$

dove $X_1, \dots, X_n$ sono variabili aleatorie a valori in $\mathbb{X}_0$ i.i.d. con densità

$$f_\theta : \mathbb{X}_o \to \mathbb{R}\,,\ f_\theta(x) := \frac{\mathrm{d}\pi_\theta^{(0)}}{\mathrm{d}\lambda_0}(x) = \frac{3\theta^3}{(\theta + x)^4}$$

Eseguiamo il conto del valore atteso quindi

$$\mathbb{E}_\theta\left[S_n\left(X_1, \dots, X_n\right)\right] = \frac{2}{n}\sum_{j=1}^{n}\mathbb{E}_\theta X_j = 2\mathbb{E}_\theta X_0$$

Il valore atteso dell'ultimo membro si può calcolare attraverso la densità

$$\mathbb{E}_\theta X_0 = \int_{\mathbb{X}_0} x f_\theta(x)\mathrm{d}x = 3\theta^3\int_0^{+\infty}\frac{x}{(\theta + x)^4}\mathrm{d}x$$

Rimane da calcolare solo l'integrale all'ultimo membro:

$$\int_0^{+\infty}\frac{x}{(\theta + x)^4} = \int_0^{+\infty}\frac{1}{(\theta + x)^3}\mathrm{d}x - \theta\int_0^{+\infty}\frac{1}{(\theta + x)^4}\mathrm{d}x = \frac{1}{6\theta^2}.$$

Pertanto S_n è uno stimatore corretto di θ perché

$$\mathbb{E}_\theta\left[S_n\left(X_1, \dots, X_n\right)\right] = \theta$$

2. Calcoliamo le varianze conoscendo la densità delle variabili aleatorie i.i.d. $X_1, \dots, X_n$ del punto precedente:

$$\mathrm{Var}_\theta\left[S_n\left(X_1, \dots, X_n\right)\right] = \frac{4}{n^2}\sum_{j=1}^{n}\mathrm{Var}_\theta X_j = \frac{4}{n}\mathrm{Var}_\theta X_0 = \frac{4}{n}\left(\mathbb{E}_\theta X_0^2 - \left(\mathbb{E}_\theta X_0\right)^2\right)$$

Dal punto precedente sappiamo che $\mathbb{E}_\theta X_0 = \frac{\theta}{2}$. Calcoliamo l'altro valore atteso:

$$\mathbb{E}X_0^2 = \int_{\mathbb{X}_0} x^2 f_\theta(x)\mathrm{d}x = 3\theta^3\int_0^{+\infty}\frac{x^2}{(\theta + x)^4}\mathrm{d}x.$$

L'integrale al secondo membro si può calcolare facilmente, per esempio ricordando che $x^2 = (\theta + x)^2 - \theta^2 - 2\theta x$. Alla fine si arriva a

$$\mathrm{Var}_\theta X_0 = \frac{3}{4}\theta^2$$

e quindi a

$$\mathrm{Var}_\theta\left[S_n\left(X_1, \dots, X_n\right)\right] = \frac{4}{n}\left(\theta^2 - \frac{\theta^2}{4}\right) = \frac{3}{n}\theta^2.$$

3. Il modello è regolare di classe C^2, quindi l'informazione di Fisher del modello di base si scrive come

$$I_0(\theta) = -\mathbb{E}_\theta\left[\frac{\partial^2}{\partial\theta^2}\log f_\theta(X)\right].$$

Calcoliamo quindi il valore atteso al secondo membro:

$$\begin{aligned}\mathbb{E}_\theta\left[\frac{\partial^2}{\partial\theta^2}\log f_\theta(X)\right] &= \mathbb{E}_\theta\left[-\frac{3}{\theta^2}+\frac{4}{(\theta+X)^2}\right] = \\ &= -\frac{3}{\theta^2}+4\mathbb{E}_\theta\left[\frac{1}{(\theta+X)^2}\right] = \\ &= -\frac{3}{\theta^2}+4\int_0^{+\infty}\frac{1}{(\theta+x)^2}f_\theta(x)\mathrm{d}x = \\ &= -\frac{3}{\theta^2}+\frac{12}{5\theta^2} = -\frac{3}{5\theta^2}\end{aligned}$$

È facile verificare la disuguaglianza a questo punto.

4. Usiamo quanto ricavato nei punti precedenti: in particolare, se $\{X_n \mid n \in \mathbb{N}\}$ è una successione di variabili aleatorie i.i.d. con densità $f_\theta = \frac{\mathrm{d}\pi_\theta^{(0)}}{\mathrm{d}\lambda_0}$, allora per ogni $j \in \mathbb{N}$

$$\begin{aligned}\mathbb{E}_\theta X_j &= \frac{1}{2}\theta \\ \mathrm{Var}_\theta X_j &= \frac{3}{4}\theta^2\end{aligned}$$

Quindi per il Teorema Centrale del Limite

$$\sqrt{n}\left(\frac{1}{n}\sum_{j=1}^n X_j - \frac{\theta}{2}\right) \to \mathcal{N}\left(0, \frac{3}{4}\theta^2\right).$$

da cui segue che

$$\sqrt{n}\left(\frac{2}{n}\sum_{j=1}^n X_j - \frac{\theta}{2}\right) \to \mathcal{N}\left(0, 3\theta^2\right)$$

che è quello che volevamo dimostrare. In particolare, $F(\theta) = 3\theta^2$.

5. $\square$